Машинное обучение в науках о Земле

Михаил Криницкий

к.т.н.,
зав. Лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Институт океанологии РАН им. П.П. Ширшова

Задачи классификации

Михаил Криницкий

к.т.н.,
зав. Лабораторией машинного обучения в науках о Земле МФТИ
с.н.с. Институт океанологии РАН им. П.П. Ширшова

КЛАССИФИКАЦИЯ ЗАДАЧ МАШИННОГО ОБУЧЕНИЯ

<u>формулируем задачу</u> (в терминах машинного обучения)

- «Обучение с учителем»
  - восстановление регрессии
  - <u>классификация</u>

что я хочу? – метку класса

«красный или синий?»

(бинарная классификация)

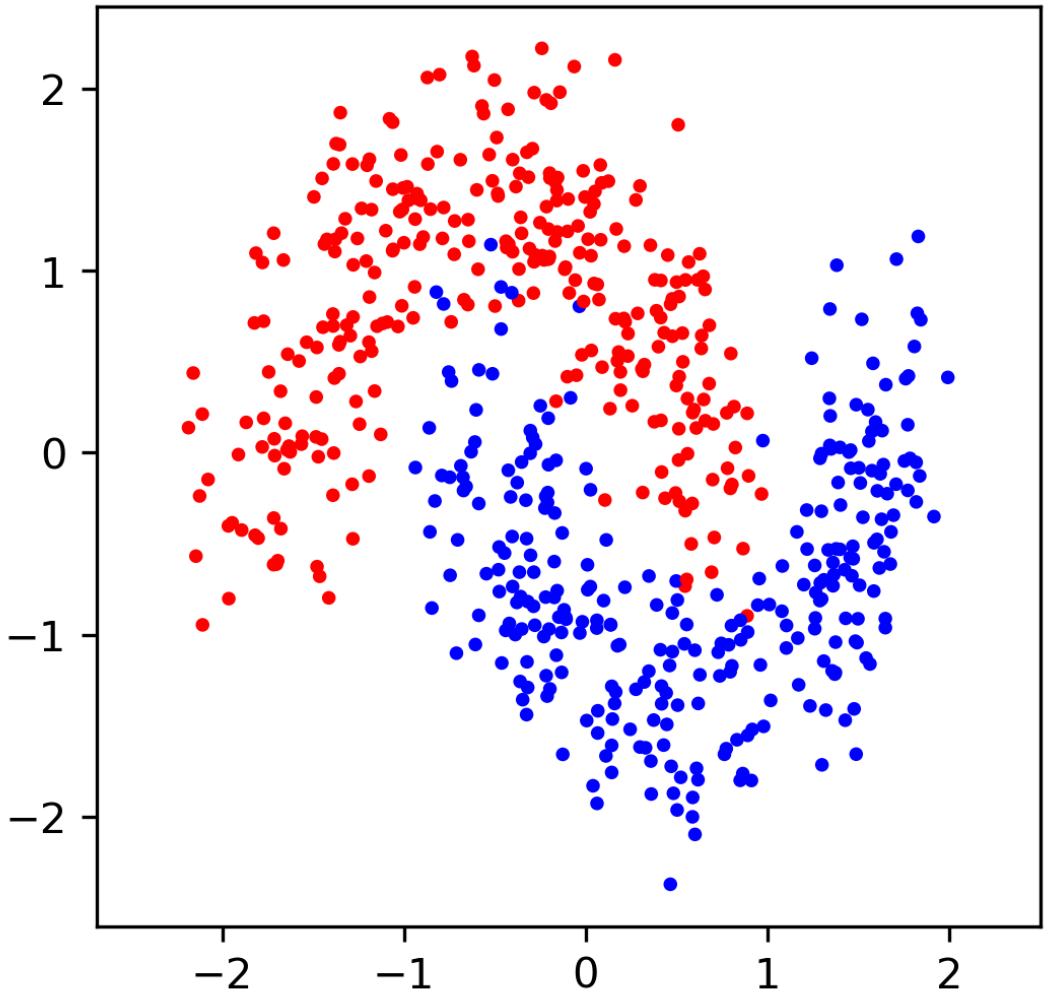

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

цель – метка класса (y – категориальная переменная)

«спам / не-спам»	y – категориальная, бинарная
«мезоциклон / не-мезоциклон»	y – категориальная, бинарная
«кот / собака / лошадь»	y – категориальная, 3 класса
«0 / 1 / 2 / 3 / 4 / 5 / 6 / 7 / 8 / 9»	y – категориальная, 10 классов
«есть дельфин / нет дельфина»	y – категориальная, бинарная

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Простейший пример: объекты описываются действительным признаком $\boldsymbol{x}$
целевая переменная $\boldsymbol{y}$ – бинарная, классы: $\boldsymbol{A}$, $\boldsymbol{B}$; по 1000 экземпляров каждого класса
пусть для класса $y = \boldsymbol{A}$ значения $x \sim \mathcal{N}(\mu_{\boldsymbol{A}}, \sigma_{\boldsymbol{A}})$, для класса $y = \boldsymbol{B}$ значения $x \sim \mathcal{N}(\mu_{\boldsymbol{B}}, \sigma_{\boldsymbol{B}})$

Базируясь на этих данных, каково должно быть решение (значение $\boldsymbol{y}$) при:

$x = -10$
$x = -5$
$x = 2$
$x = 5$
$x = 10$
$x = 15$

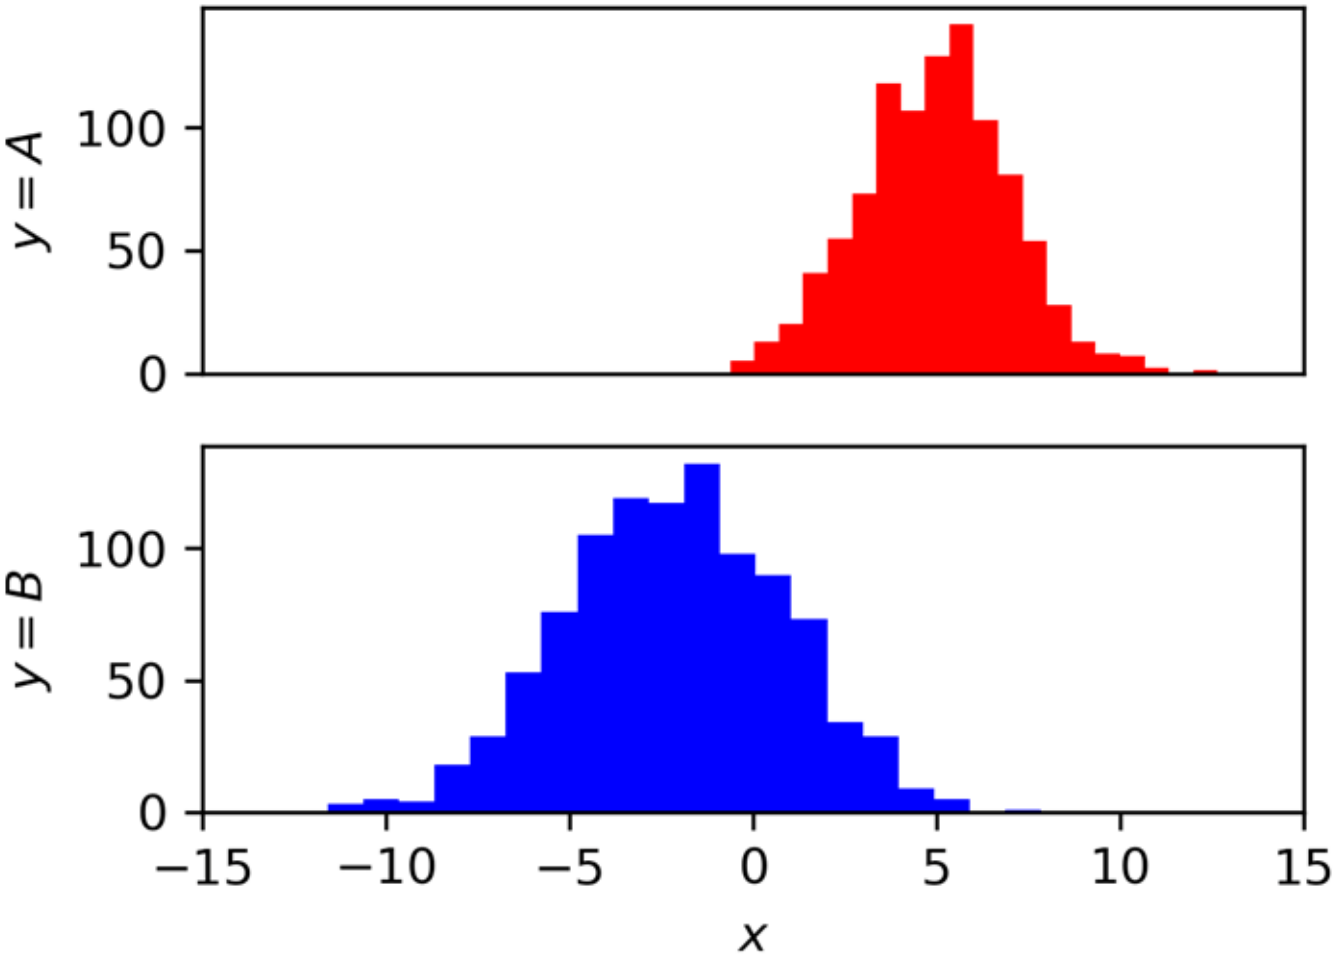

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Naïve bayes classifier, «наивный байесовский классификатор»

$$P(Y|X) \propto P(X|Y)\ \ P(Y)$$

Наивное предположение об условной независимости предикторов	$P(x_p \mid Y = k, x_1, x_2, \dots, x_{p-1}) = P(x_p \mid Y = k)$
Оценка параметров распределений (отдельно для каждого класса, для каждой компоненты признакового описания), подстановка в ф-лу Байеса	$P(Y = k \mid X = x) \propto P(Y) * \prod_{j=1}^{p} P(x_j \mid Y = k)$
Вычисление вывода модели	$\hat{y}(x) = \mathrm{argmax}(P_k(x))$
Нормировка вероятностей (если нужны оценки вероятностей)	$P_k(x) = \frac{P(Y = k \mid X = x)}{\sum_k P(Y = k \mid X = x)}$

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Naïve bayes classifier, «наивный байесовский классификатор»

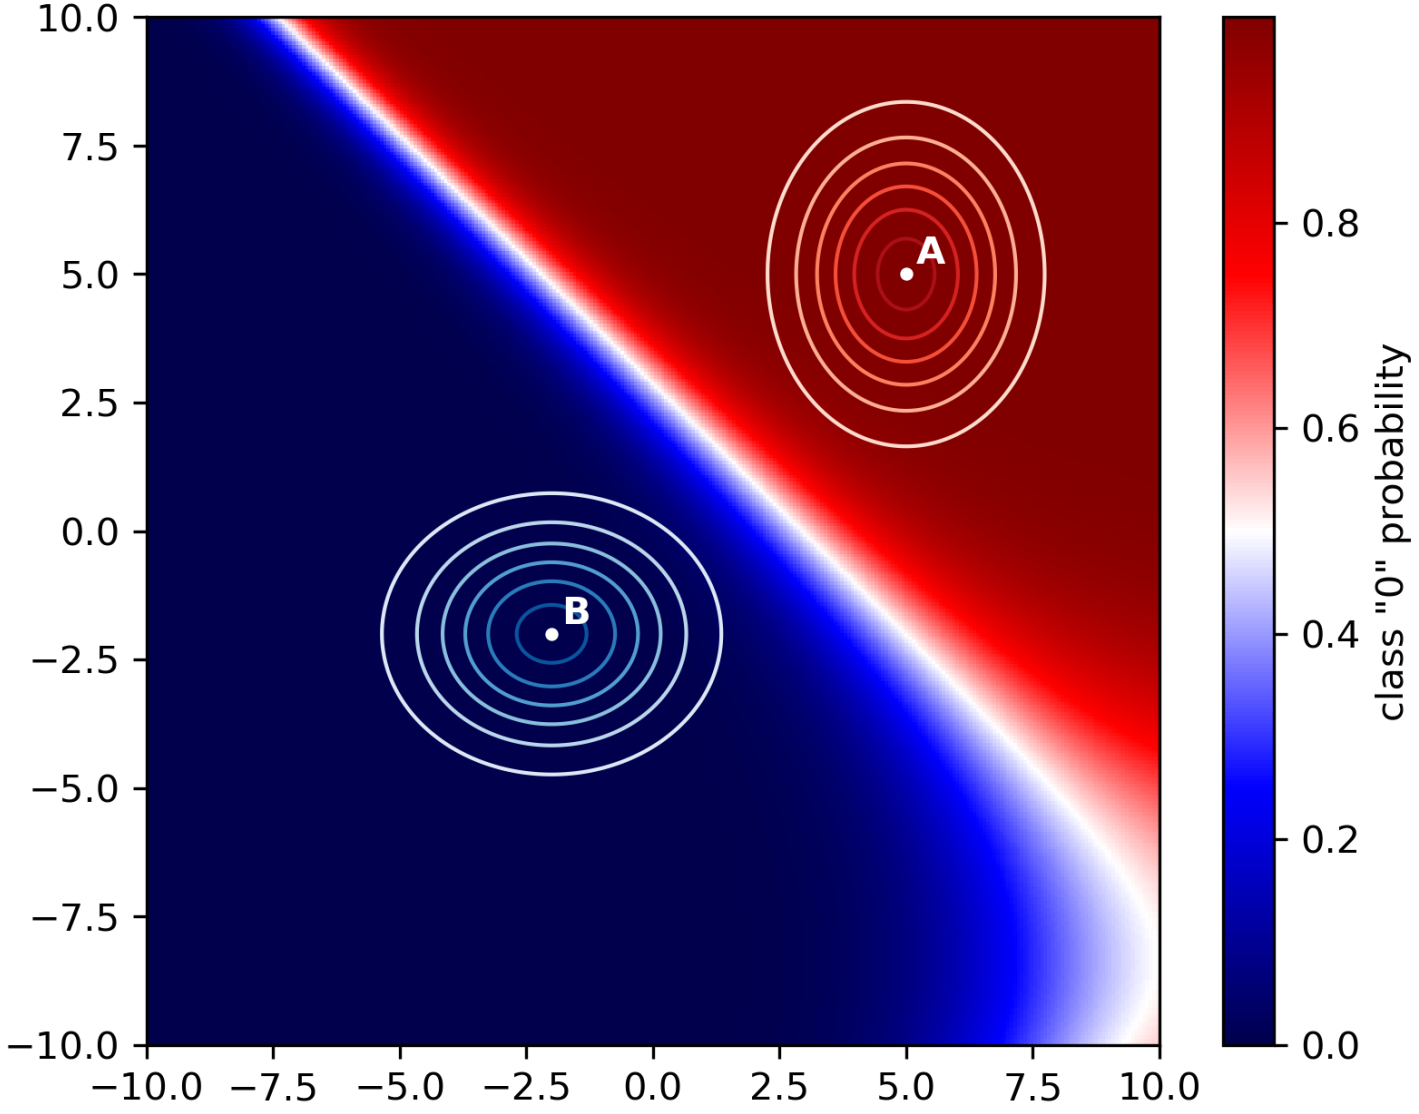

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Разделяющая поверхность
(на примере результатов наивного байесовского классификатора)

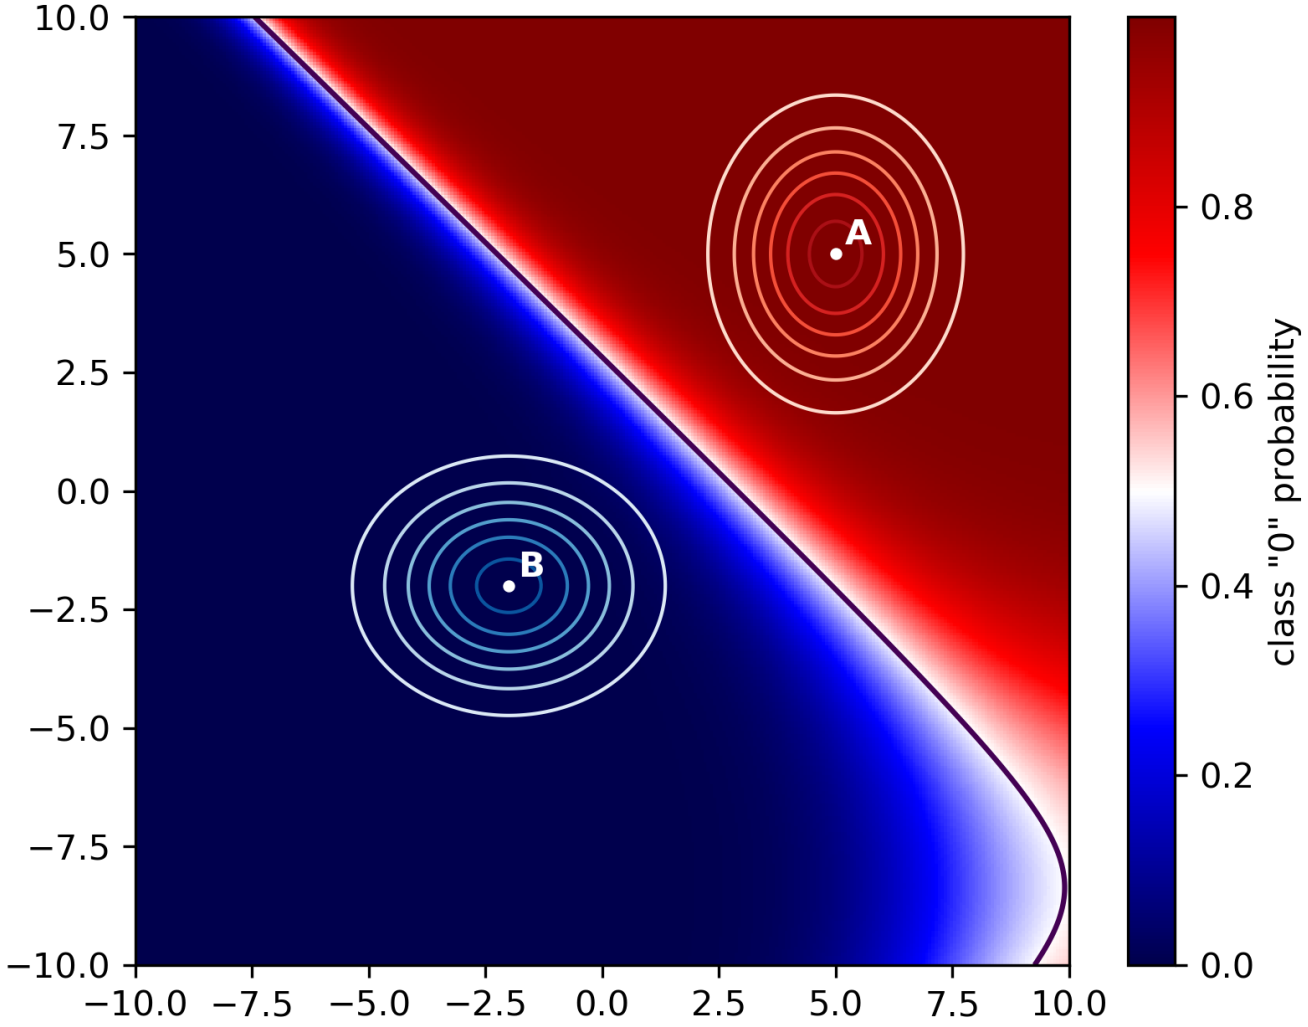

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

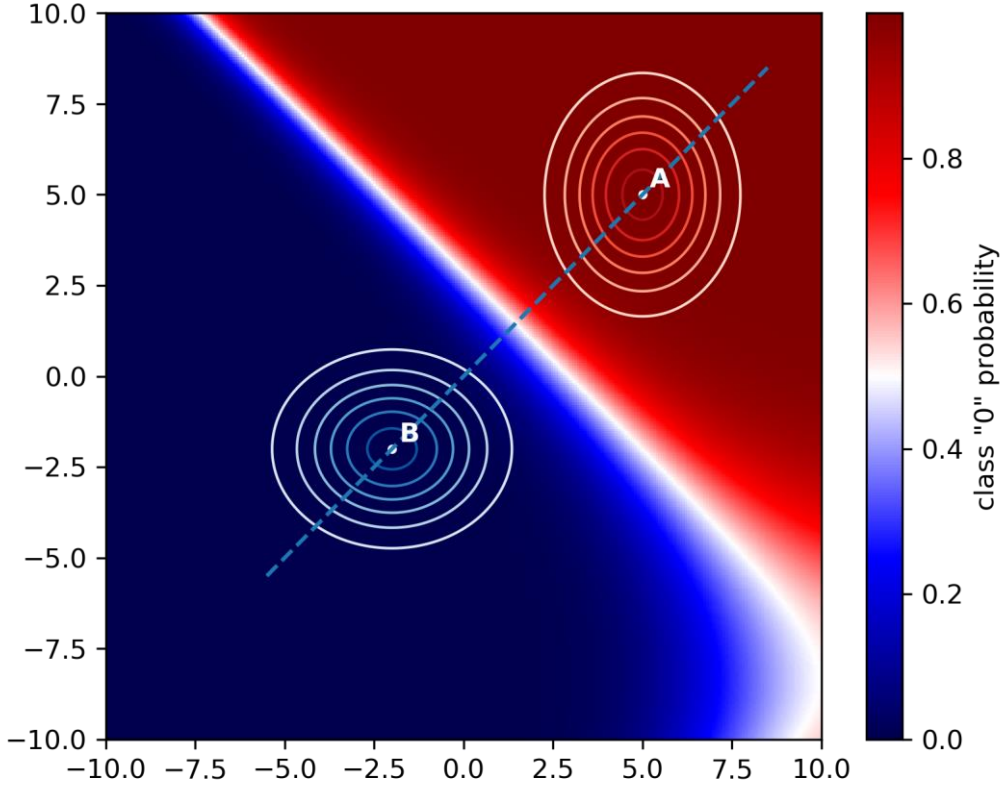

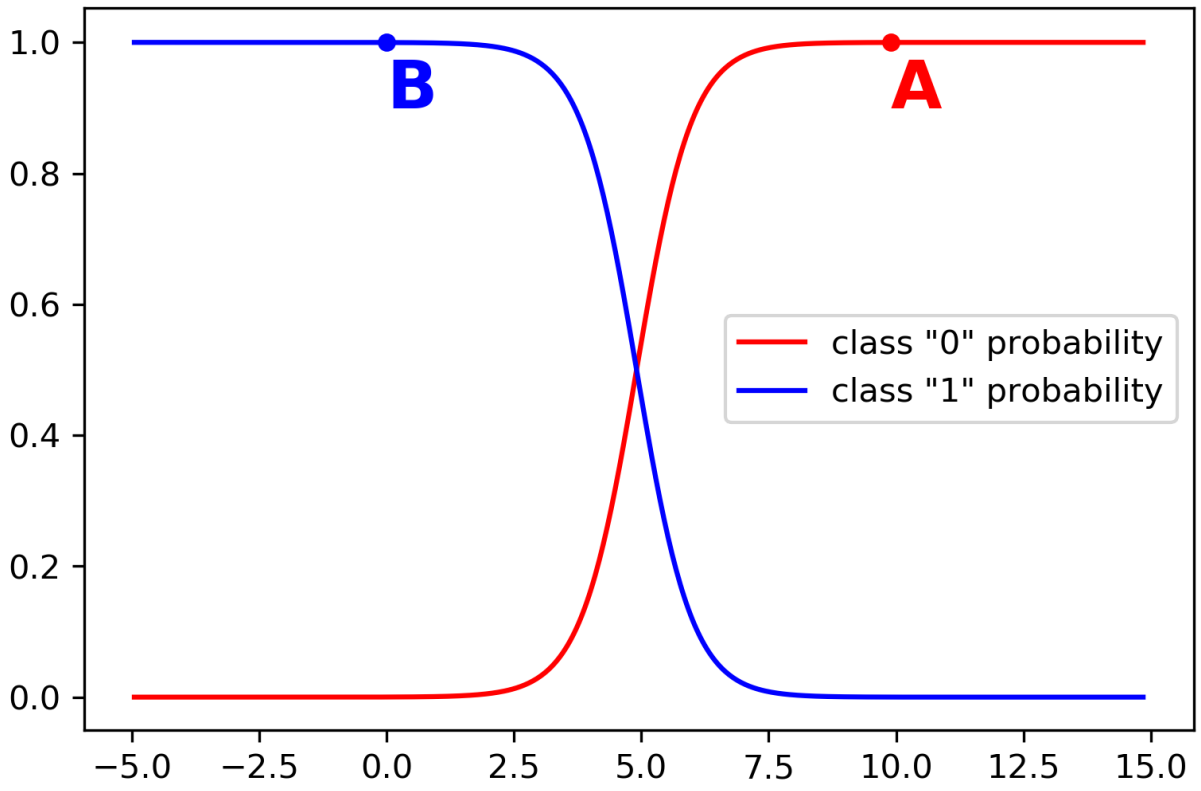

Может быть, можно аппроксимировать $P(y = 0|x)$ на основании данных обучающей выборки?
Разве не для этого придуман весь подход машинного обучения?

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Логистическая регрессия («logistic regression»)

Линейная регрессия: набор предположений “LINE”

$$y_i \sim \mathcal{N}(\theta \cdot x_i, \sigma^2)$$

$$L(\mathcal{T}) = P(\{y_i, x_i\}) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}}$$

$$\ell(\mathcal{T}, \theta) = \log L(\mathcal{T}, \theta) = \sum_{i=1}^{N} \log\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^{N} \frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}$$

$$\theta^* = \underset{\Theta}{\operatorname{argmax}}\big(\ell(\mathcal{T}, \theta)\big) = \underset{\Theta}{\operatorname{argmin}} \sum_{i=1}^{N} \frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}$$

Логистическая регрессия:

(1) Предполагаем, что переменная Y распределена согласно распр-ю Бернулли с параметром p (зависящий от x_i);
(2) Предполагаем, что отношение log-вероятностей классов «1» и «0» соотносятся как линейная функция:

$$f(\theta, x) = \theta \cdot x$$

$$Y \sim \mathcal{B}\big(p(\theta, x)\big), \qquad \log \frac{p(\theta, x)}{1 - p(\theta, x)} = \theta \cdot x$$

$$p(\theta, x) = \frac{1}{1 + e^{-\theta \cdot x}}$$

$$L(\mathcal{T}) = \prod_{i=1}^{N} \left(p(x_i)^{y_i} * \big(1 - p(x_i)\big)^{(1 - y_i)} \right)$$

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Логистическая регрессия («logistic regression»)

$\log\frac{p(\theta,x)}{1-p(\theta,x)} = \theta\cdot x, \qquad p(\theta,x) = \frac{1}{1+e^{-\theta\cdot x}}$

Новое обозначение (для краткости): $p_i \equiv p(\theta, x_i)$

$$L(\mathcal{T}) = \prod_{i=1}^{N}\left(p_i^{y_i} * (1-p_i)^{(1-y_i)}\right)$$

Бинарная перекрестная энтропия (отрицательная)

Negative binary cross-entropy

$$\ell(\mathcal{T},\theta) = \log(L(\mathcal{T},\theta)) = \sum_i \log\left(p_i^{y_i}\right) + \sum_i \log\left((1-p_i)^{(1-y_i)}\right) =$$

$$= \sum_i (y_i * \log p_i + (1-y_i) * \log(1-p_i)) = \sum_i \log(1-p_i) + \sum_i y_i * \log\frac{p_i}{1-p_i} =^{(*)}$$

$$\left\{p_i = \frac{1}{1+e^{-\theta\cdot x_i}} \;:\; (1-p_i) = \frac{1}{1+e^{\theta\cdot x_i}}\right\}$$

$$\left\{\log\frac{p_i}{1-p_i} = \theta\cdot x_i\right\}$$

$$(*) = -\sum_i \log\left(1+e^{\theta\cdot x_i}\right) + \sum_i y_i * \theta\cdot x_i$$

$$\frac{\partial\ell(\mathcal{T},\theta)}{\partial\theta} = \sum_i \left(y_i - p(\theta,x_i)\right)x_i$$

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Логистическая регрессия («logistic regression»)

Линейная регрессия:

набор предположений “LINE”

$$y_i \sim \mathcal{N}(\theta \cdot x_i, \sigma^2)$$

$$L(\mathcal{T}) = P(\{y_i, x_i\}) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}}$$

$$\ell(\mathcal{T}, \theta) = \log L(\mathcal{T}, \theta) = \sum_{i=1}^{N} \log\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^{N} \frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}$$

$$\theta^* = \underset{\Theta}{\operatorname{argmax}}\big(\ell(\mathcal{T}, \theta)\big) = \underset{\Theta}{\operatorname{argmin}} \sum_{i=1}^{N} \frac{(y_i - \theta \cdot x_i)^2}{2\sigma^2}$$

Логистическая регрессия:

(1) Предполагаем, что переменная Y распределена согласно распределению Бернулли с параметром p;
(2) Предполагаем, что отношение log-вероятностей классов «1» и «0» соотносятся как линейная функция $f(\theta, x) = \theta \cdot x$

$$Y \sim \mathcal{B}\big(p(\theta, x)\big), \qquad \log \frac{p(\theta, x)}{1 - p(\theta, x)} = \theta \cdot x, \quad p(\theta, x) = \frac{1}{1 + e^{-\theta \cdot x}}$$

$$L(\mathcal{T}) = \prod_{i=1}^{N} \left(p(x_i)^{y_i} * \big(1 - p(x_i)\big)^{(1 - y_i)}\right)$$

$$\ell(\mathcal{T}, \theta) = -\sum_{i} \log\big(1 + e^{\theta \cdot x_i}\big) + \sum_{i} y_i * \theta \cdot x_i$$

$$\theta^* = \underset{\Theta}{\operatorname{argmax}}\big(\ell(\mathcal{T}, \theta)\big) = \underset{\Theta}{\operatorname{argmin}} \left(\sum_{i} \big(\log\big(1 + e^{\theta \cdot x_i}\big) - y_i * \theta \cdot x_i\big)\right)$$

$$\underset{\Theta}{\operatorname{argmax}} \sum_{i} (y_i * \log p_i + (1 - y_i) * \log(1 - p_i))$$

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации

Логистическая регрессия («logistic regression»)

code demonstration

ОБУЧЕНИЕ С УЧИТЕЛЕМ: задача классификации
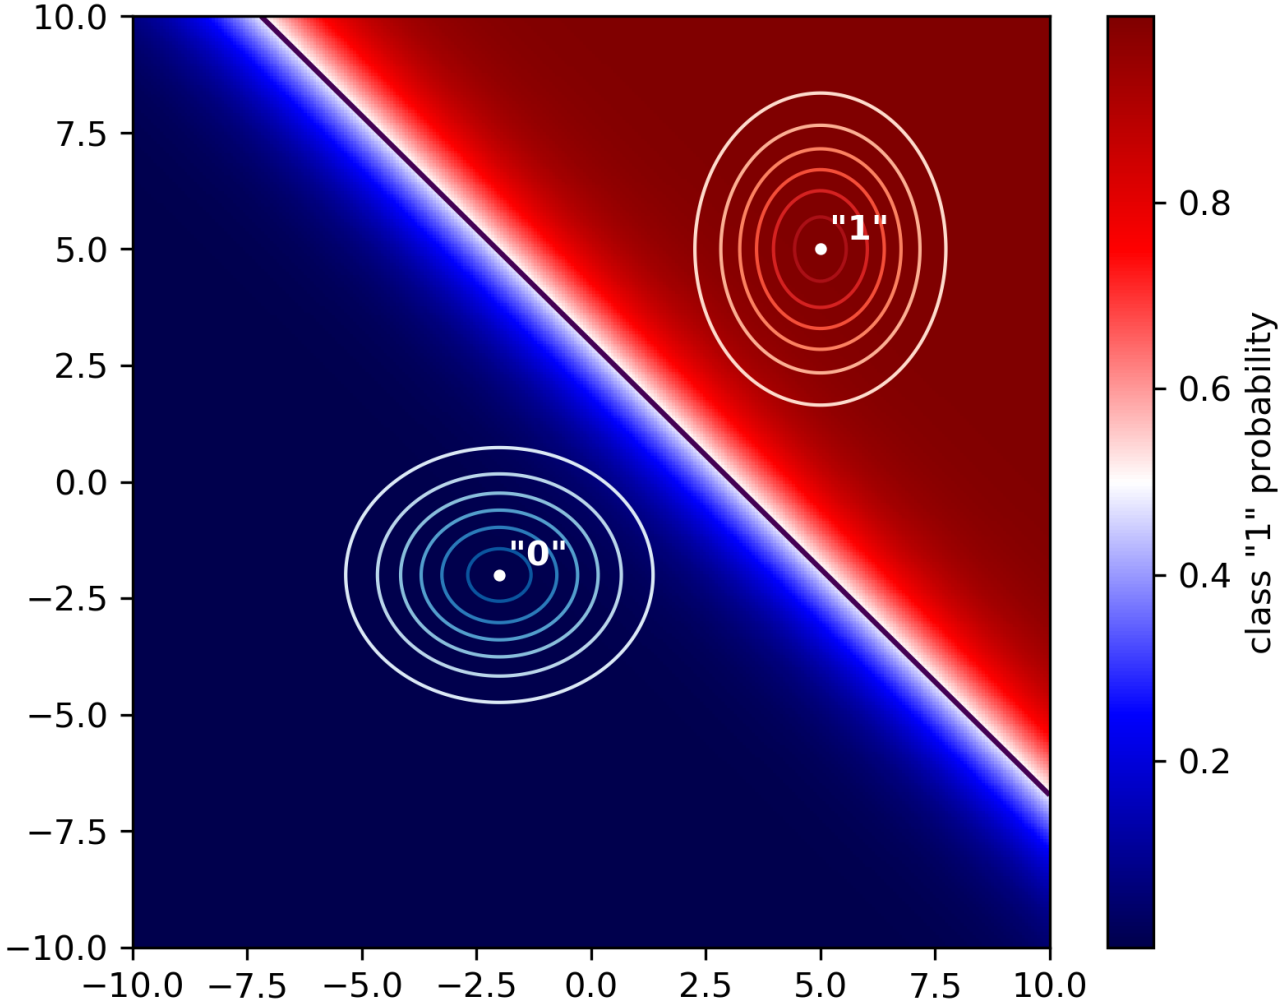
Разделяющая поверхность
(на примере результатов логистической регрессии)